Carga, resiliência e observabilidade

Evolução dos testes da Sprint 3, com cenários executáveis, resultados auditáveis e impacto nas decisões de arquitetura. Develop d5339f3 incorporado; a linha de base ECS e um EKS dedicado foram medidos separadamente.

Critério	Peso	Entrega verificável
Planos de RNFs	3,0	Cenários, pré-condições, massa, procedimento, métricas e aceite objetivo.
Resultados e análise	4,0	Carga real, falha injetada, recuperação, recontagem independente e limites de interpretação.
Grafana / Prometheus	3,0	Quatro indicadores com amostras reais, queries preservadas e gate por expressão visível.

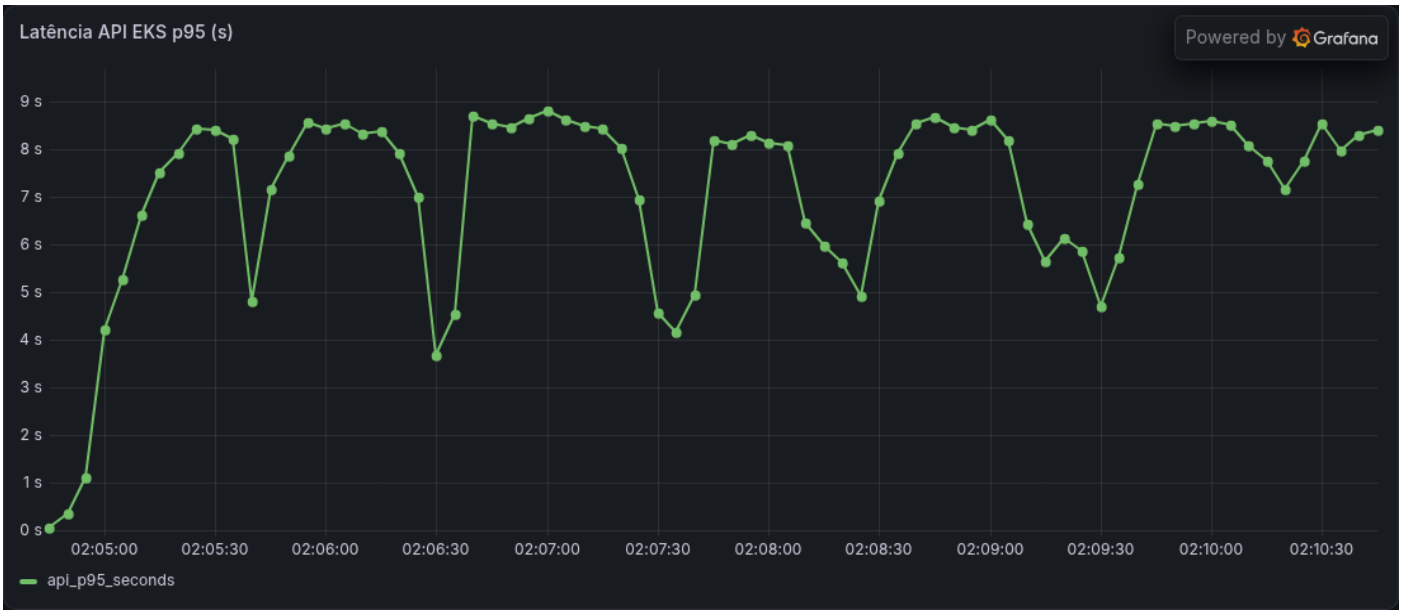
Resultados centrais

Experimento	Medido	Conclusão
Chegada contínua local	150.000 eventos / 15 min; p95 do lote 1,179 s	150.000 verificados; sem faltantes, duplicados ou diferenças canônicas.
Volume AWS	750.000 em 23 datasets recontados	INGESTING completo; pipeline não concluiu no orçamento de 75 min.
EKS nominal	150 mil; PROCESSING após 904,60 s	Reprovado/censurado; o smoke de 1.000 chegou a READY em 120,648 s.
API EKS 137/s	43.198 req; p95 geral 8 s; 93,990% de falha	HPA 1→4 não evitou saturação; 1.003 chegadas descartadas.
Falha e recuperação	MySQL bloqueado: 2 tentativas / 2,017 s	Recupera a mesma página em 5,866 ms após liberar o lock.
Frontend autenticado	18 auditorias; FCP móvel até 1,173 s	Três telas e API real; LCP móvel ultrapassa a referência de 2,5 s.

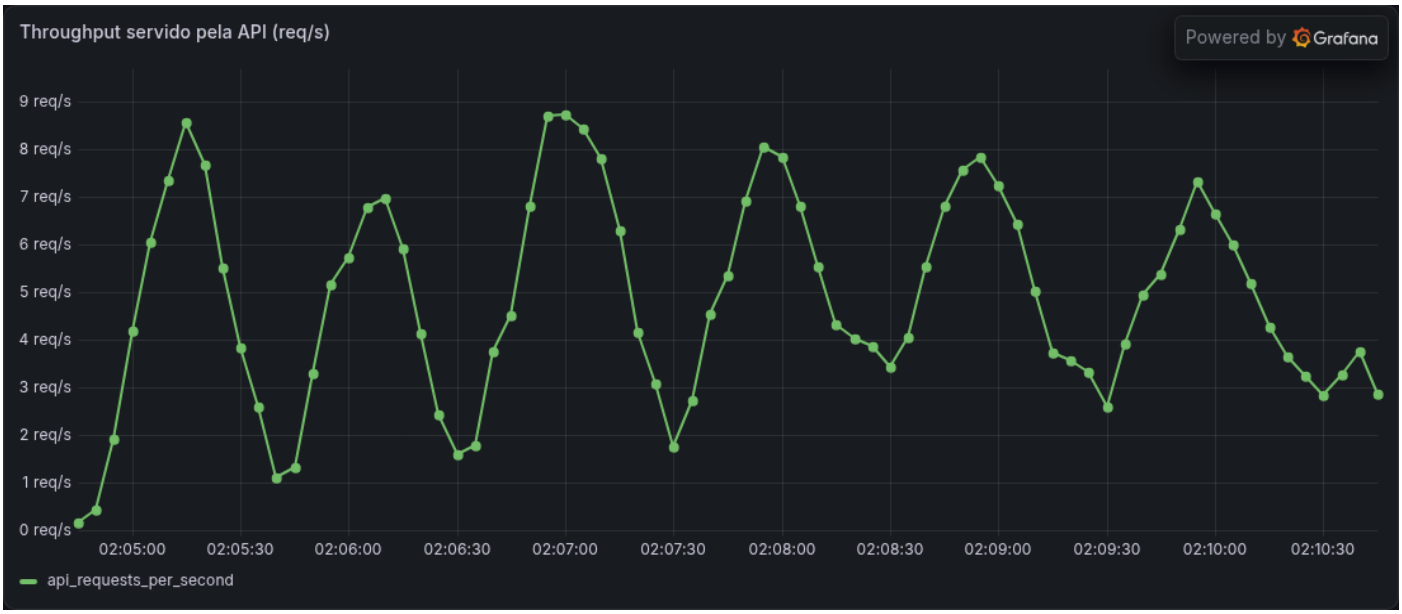
Perfis: nominal 150 mil/900 s; 2× volume 300 mil/1.800 s; 5× volume 750 mil/4.500 s. Batch sem rampa. Contínuo: 1.000 eventos/6 s durante 900 s, 150 mil no total. Os multiplicadores são de volume; taxas de chegada 20/50 mil por minuto ainda são planos futuros.

API EKS: latência e vazão

Conta 239162056821, us-east-1. Janela: 07/10 02:04:45-02:10:45 UTC. Exportação retrospectiva nativa do Grafana sobre frames Prometheus preservados. A taxa oferecida de 137/s não se converteu em throughput útil.



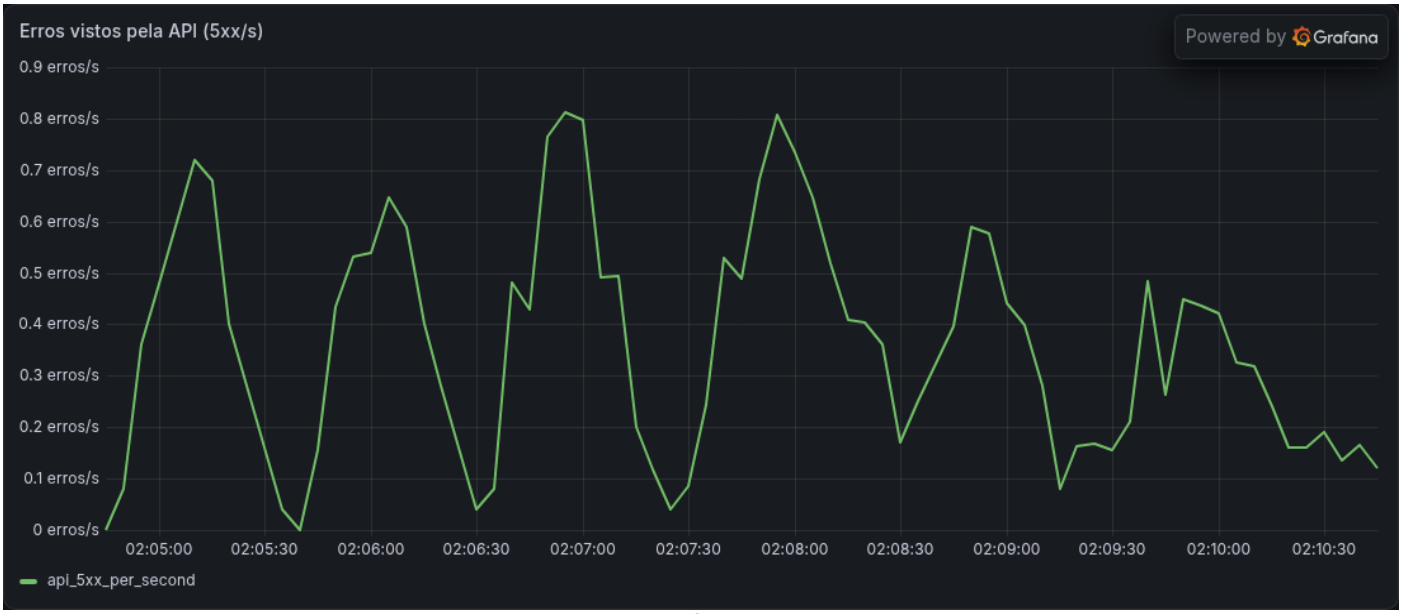
O p95 chega perto de 8 s, acima do critério de 2 s. K6 inclui também rede e timeout do cliente.



A vazão do servidor oscila em poucos req/s. Requisições que falham no balanceador ou expiram podem não entrar nessa série.

API EKS: erros e CPU

A fórmula corrigida de CPU soma os containers em percentual de um núcleo. O gate da visualização confirma 73 amostras por indicador; as séries não são uma nova carga.



São os 5xx que alcançaram o processo. O k6 contou também 29.292 respostas com status 0 e 12.323 respostas 503 na rodada.



Percentual agregado de um núcleo, podendo superar 100% com réplicas. Não usar a antiga divisão por número de Pods com scrape saudável.

Método, decisões e rastreabilidade

Repetibilidade: 3/3 repetições com resultado fechado na geração desta edição. Cada massa tem 150.000 registros, distribuição de uma janela e hash independente; orçamento de 900 s pré-definido. Não combinar percentis ou versões históricas como se fossem amostras do mesmo perfil.

Capacidade do lote de 150 mil (ECS, 04/10)

Etapa	Tempo	Taxa média
INGESTING	447,512 s	20.111 eventos/min
PROJECTING	958,073 s	9.394 eventos/min
ARCHIVING	778,185 s	11.565 eventos/min

Em sequência, os tempos se somam: 2.183,770 s → 4.121 eventos/min. r_total = 1/(1/r1+1/r2+1/r3). Os 3.956 medidos pelo k6 incluem partida e polling. CPU de ~21% na ingestão/projeção; arquivo chega a 50,9% de duas vCPUs, um núcleo ocupado.

Evidência	Decisão / limite
Taxa sequencial abaixo de 10 mil/min	Proposta: otimizar projeção e paralelismo limitado no arquivo.
750 mil censurado após o prazo	Contagem independente não aprova conclusão end-to-end; cancelamento é operacional, não deadline nativo.
RS-06: zero 429 na URL pública	Proposta: identificar cliente pela cadeia de proxies confiáveis e repetir público/direto.
Heartbeat drena 2/3/4 lotes	Implementado e medido em ECS. Alarme por idade já existe; janela e cobertura precisam revisão.
Probes da API falham sob saturação	Proposta: contrapressão, cancelamento e revisão de saúde antes de repetir carga.

Mapa para conferir a entrega

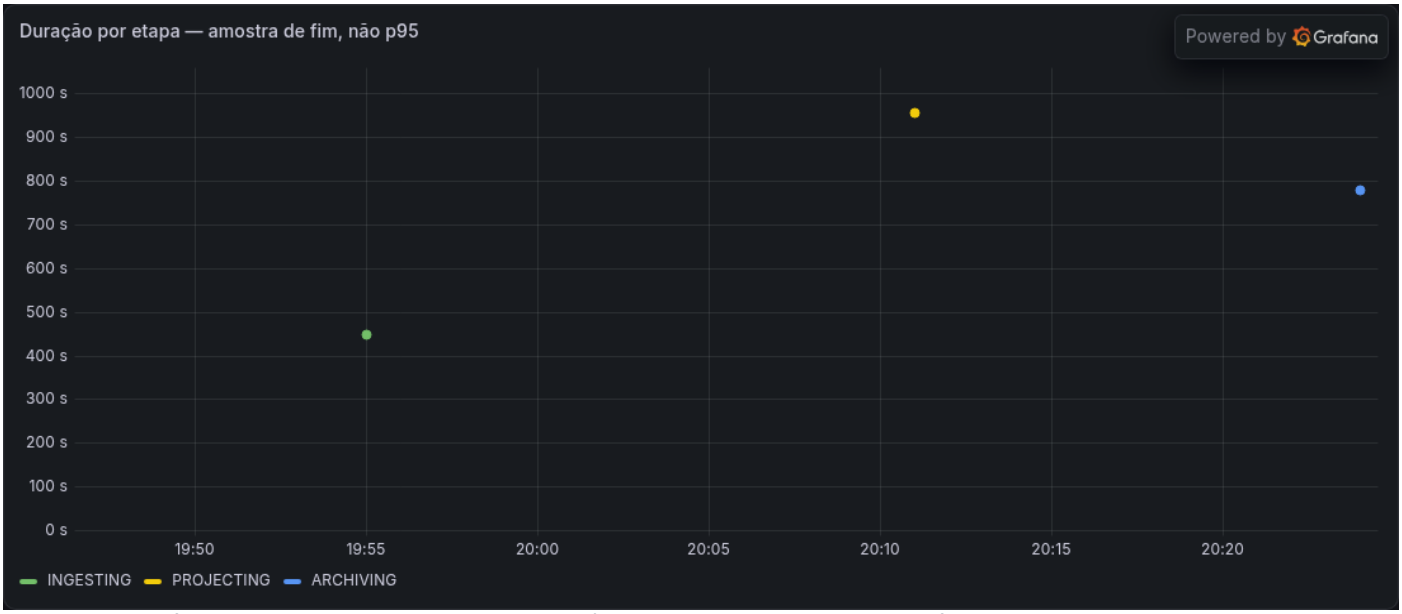
Artefato principal: artefatos/testes-carga-finais.md
Brutos e proveniência: assets/testes-carga/2026-10-06-fechamento-local/ e 2026-10-06-fechamento-aws/
Reprodução: apps/backend/api/loadtest/lab/README.md
Anexo: artefatos/apoio/testes-carga-inventario.md - enumeração dos Dockerfiles, manifests e configurações. Grafana retrospectivo: apps/backend/api/loadtest/grafana-retroativo/README.md.

Limites que permanecem explícitos

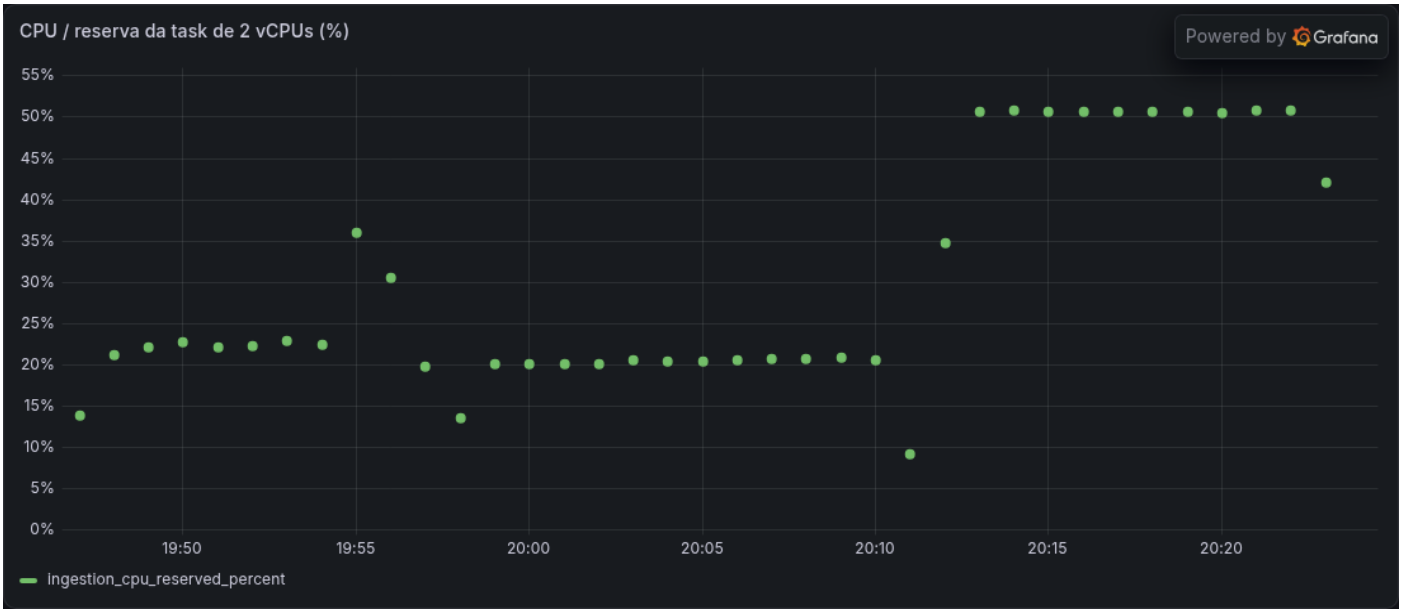
Laboratório e massas sintéticas; imagem implantada separada do commit; o EKS teve API e ingestão nativas, mas o nominal de 150 mil excedeu o orçamento; 17 testes de manifests e 14 de adaptadores não substituem essa carga; três auditorias não provam percentil populacional; login Cognito não medido; soak finito não prova disponibilidade mensal; erro da UI não aprova funcionalidade.

Ingestão: o custo das etapas

ECS, 04/10 19:46:30-20:24:31 UTC. Mesma massa concentrada de 150 mil eventos. As durações são amostras agregadas de fim de etapa, não p95 nem uma série de latência contínua.



PROJECTING é a maior etapa: 958 s, 43,9% dos três tempos somados; sozinho já excede os 900 s do nominal.



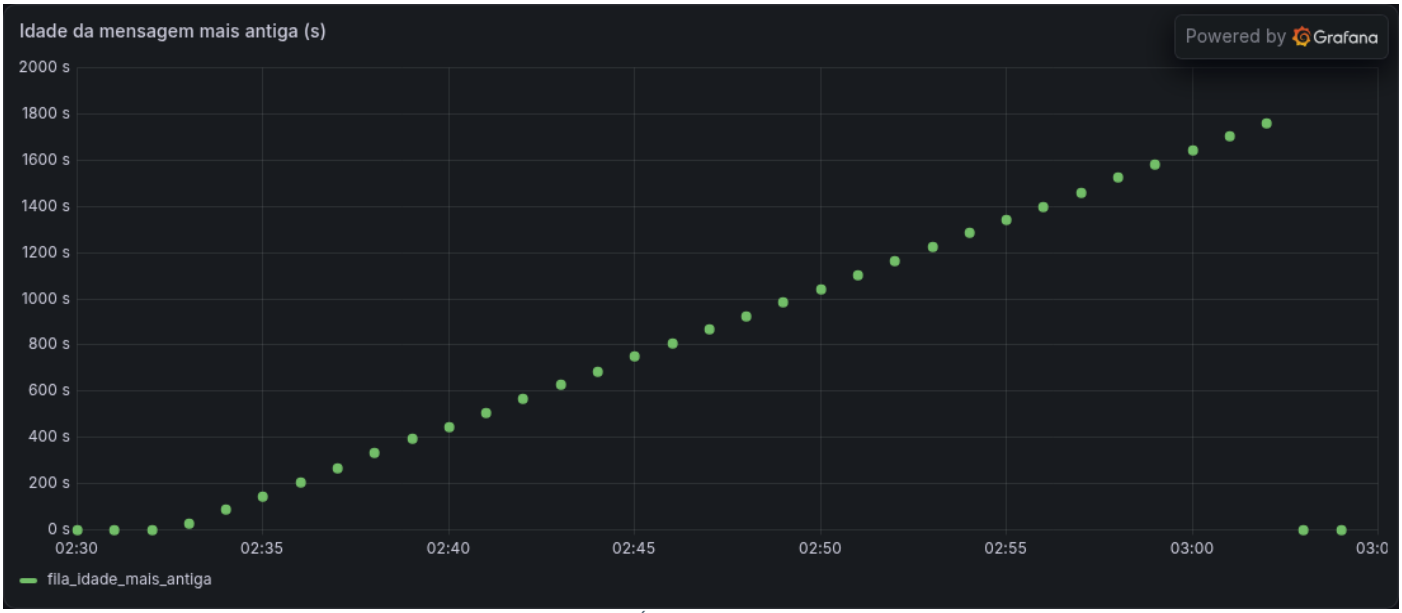
CPU média ~21% na ingestão/projeção; ARCHIVING chega a 50,9% de duas vCPUs. Memória máxima cresce de 14,5% (150 mil) para 26,0% (300 mil), sem throttling DynamoDB.

Fila: acúmulo e recuperação

RS-01, três lotes de 150 mil. Fila cheia é backlog além da capacidade de consumo, não um pequeno limite rígido da SQS. Ao retomar o consumidor, 450 mil fatos foram persistidos e a DLQ permaneceu vazia.



Três mensagens representam 450 mil eventos. O último lote concluiu em 1.334 s após reativar a agenda; o monitor confirmou fila vazia aos 1.371 s.



A idade chega a ~1.762 s e cai depois da drenagem. É um sinal operacional de atraso, diferente de latência HTTP; alarme de idade existe, mas sua janela ainda não garante 30 s.

Recuperação por falha

RS-02a: 503 em 0,58 s e READY ~170 s após restaurar S3. RS-02b: FAILED ~130 s após parar worker, posse livre em ~5,5 min. RS-05: mensagem venenosa vai à DLQ em ~29 min úteis; válido +150 mil; alarme 131-158 s, acima de 30 s. Esses tempos pertencem a cenários distintos.