Carga, resiliência e observabilidade

Evolução dos testes da Sprint 3, com cenários executáveis, resultados auditáveis e impacto nas decisões de arquitetura. Develop d5339f3 incorporado; a linha de base ECS e um EKS dedicado foram medidos separadamente.

Critério	Peso	Entrega verificável
Planos de RNFs	3,0	Cenários, pré-condições, massa, procedimento, métricas e aceite objetivo.
Resultados e análise	4,0	Carga real, falha injetada, recuperação, recontagem independente e limites de interpretação.
Grafana / Prometheus	3,0	Quatro indicadores com amostras reais, queries preservadas e gate por expressão visível.

Resultados centrais

Experimento	Medido	Conclusão
Chegada contínua local	150.000 eventos / 15 min; p95 do lote 1,179 s	150.000 verificados; sem faltantes, duplicados ou diferenças canônicas.
Volume AWS	750.000 em 23 datasets recontados	INGESTING completo; pipeline não concluiu no orçamento de 75 min.
Falha e recuperação	MySQL bloqueado: 2 tentativas / 2,017 s	Recupera a mesma página após liberar o lock; timeout é real.
Frontend autenticado	18 auditorias; FCP móvel até 1,173 s	Três telas e API real; LCP móvel ultrapassa a referência de 2,5 s.

Uma reprovação não é ausência de entrega. O resultado de capacidade foi preservado como falha; nenhuma configuração, janela ou imagem é atribuída a uma execução que não a mediu.

Observabilidade durante a carga AWS

Conta 239162056821, us-east-1. Janela: 06/10 23:10-23:42 UTC. Latência, throughput e erros são das rotas de importação; CPU é da task import-dump sobre a reserva ECS. Throughput HTTP não é vazão de eventos.



Latência p95 do plano de controle. Histograma do servidor; a medição k6 também inclui a internet.



Throughput das rotas /imports. A atividade de consulta não representa a taxa de processamento do worker.

Erros e recurso utilizado

As imagens são exportações nativas do Grafana, sem redesenho das séries. O gate exige status 200, valores numéricos e nenhuma falha de datasource em cada query exibida.



Erros/s nas rotas /imports. Zero foi derivado de um contador efetivamente coletado; ausência de série não é preenchida como sucesso.



CPU usada / CPU reservada da família import-dump. Não confundir com CPU do processo por núcleo nem com CPU do gerador.

Método, decisões e rastreabilidade

Repetibilidade: 3/3 repetições com resultado fechado na geração desta edição. Cada massa tem 150.000 registros, distribuição de uma janela e hash independente; orçamento de 900 s pré-definido. Não combinar percentis ou versões históricas como se fossem amostras do mesmo perfil.

Evidência	Decisão / limite
INGESTING atende isoladamente; projeção atrasa	Otimizar PROJECTING e ARCHIVING antes de aumentar CPU sem evidência.
750 mil censurado após o prazo	Contagem independente não aprova conclusão end-to-end; cancelamento é operacional, não deadline nativo.
LeaseBusy depois de interromper task	Respeitar o TTL da posse; mapear contenção para resposta retentável e observável.
Alarme em 18,448 s nesta amostra	Resultado pontual atende 30 s; período de 300 s e morte externa não garantem cobertura.
Dois grupos FIFO válidos chegam à DLQ	Reproducer de componente documenta a falha de posse global; RNF03 não é aprovado por ele.

Mapa para conferir a entrega

Artefato principal: artefatos/testes-carga-finais.md
Brutos e proveniência: assets/testes-carga/2026-10-06-fechamento-local/ e 2026-10-06-fechamento-aws/
Reprodução: apps/backend/api/loadtest/lab/README.md
Inventário individual: scripts, queries, Terraform e os três Dockerfiles, com base, dependências, COPY, build, inicialização, usuário, portas e .dockerignore.

Limites que permanecem explícitos

Laboratório e massas sintéticas; imagem implantada separada do commit; o EKS teve API e ingestão nativas, mas o nominal de 150 mil excedeu o orçamento; 17 testes de manifests e 14 de adaptadores não substituem essa carga; três auditorias não provam percentil populacional; login Cognito não medido; soak finito não prova disponibilidade mensal; erro da UI não aprova funcionalidade.